

Projet Data Analytics Spark + MLlib + Sécurité (version GitHub)

Objectif

En binôme, les étudiants doivent produire un **pipeline Spark complet**, depuis la collecte des données jusqu'à l'analyse avancée avec MLlib, en incluant la **sécurisation des données** et les **agrégations pour reporting**.

L'ensemble du projet doit être **hébergé sur GitHub**, avec un **README détaillé** expliquant toutes les étapes, les choix et les interprétations.

Workflow intégré du projet

1. Choix des datasets

- Récupérer **deux datasets volumineux** ($\geq 100\,000$ lignes chacun) sur un sujet concret (transport, santé, finance, consommation...).
- Exemples :
 - [NYC Taxi & Limousine Trip Data](#)
 - Open Food Facts
 - Base DVF – Transactions immobilières France
- Justifier le choix des datasets et le problème métier que vous souhaitez explorer.

2. Nettoyage et préparation

- Traiter les valeurs manquantes et formats inconsistants.
- Préparer les colonnes pour réaliser la **jointure**.
- Justifier vos transformations.

3. Jointure des datasets

- Réaliser la jointure sur des clés pertinentes.

- Justifier le choix des clés et la pertinence de la jointure.

4. Sécurisation des données

- Identifier les colonnes sensibles.
- Si aucune donnée sensible réelle n'est présente → **simuler des colonnes sensibles** (ex : ID clients, emails).
- Appliquer des techniques de sécurisation :
 - Hashage (SHA-256) pour pseudonymiser les identifiants
 - Masquage partiel pour colonnes confidentielles
- Justifier vos choix et expliquer comment la sécurité est assurée.

5. Agrégations et export pour reporting

- Calculer des **indicateurs clés** (moyenne, somme, top N, taux, segmentation, etc.) pour la direction.
- Exporter le (s) **DataFrame (s) sécurisé (s) et agrégé (s)**.
- Justifier le choix des agrégations et leur utilité pour le reporting.

6. Analyse avancée avec MLlib

- Choisir un algorithme adapté :
 - Clustering (KMeans)
 - Régression (Linear Regression, Decision Tree)
 - Classification (Logistic Regression, Random Forest)
- Former le modèle, l'évaluer et interpréter les résultats.
- Justifier le choix du modèle et l'interprétation des résultats.

7. Visualisation et interprétation

- Créer des graphiques synthétiques pour illustrer vos insights.
- Les visualisations doivent être intégrées dans le notebook et expliquées.

Livrables GitHub

- **Notebook Spark** complet : ingestion, nettoyage, jointure, sécurisation, agrégations, MLlib, visualisations
- **DataFrames exportés** sécurisés et agrégés
- **README.md** détaillé :
 - Sujet et datasets choisis
 - Nettoyage et jointure
 - Sécurisation des données
 - Agrégations et insights pour la direction
 - Choix et interprétation du modèle MLlib
 - Visualisations et interprétation
- **Lien GitHub** à inclure en bas du notebook.

Inspirez-vous de ce projet pour le format du README et de l'organisation :
https://github.com/Esther-Wend/Package_R_sisepls

Grille de notation – Projet Data Analytics Spark + MLlib + Sécurité

Catégories	Critères	Points	Commentaires
1. Collecte et choix des datasets	Qualité et pertinence des datasets choisis ($\geq 100\,000$ lignes chacun), justification du choix par rapport à la problématique	2	Les datasets doivent être cohérents et pertinents pour le problème métier
2. Nettoyage et préparation des données	Traitement des valeurs manquantes, formats corrects, préparation pour jointure	2	Les transformations doivent être logiques et justifiées
3. Jointure des datasets	Jointure correcte sur clés pertinentes, justification de la logique de jointure	2	La jointure doit enrichir les données de manière cohérente
4. Sécurisation des données	Identification des données sensibles ou simulation de colonnes sensibles, application correcte du hashage, pseudonymisation ou masquage	3	La sécurisation doit être fonctionnelle et documentée
5. Agrégations et export pour reporting	Calcul d'indicateurs clés pertinents pour la direction, export des DataFrames sécurisés et agrégés	3	Les agrégations doivent être pertinentes et correctement exécutées
6. Analyse MLlib	Choix approprié du modèle (clustering, classification, régression), mise en œuvre correcte et interprétation des résultats	3	Le modèle doit correspondre au problème et être justifié
7. Visualisations et interprétation	Graphiques clairs et explicatifs, interprétation des insights	2	Visualisations compréhensibles et pertinentes pour le reporting
8. Documentation GitHub / README	README complet : explications des choix, descriptions des étapes, interprétation des résultats, lien GitHub présent	3	La documentation doit permettre à un lecteur externe de comprendre le projet et ses résultats